



초기 활력징후 및 ICD 진단코드 기반 입원 예측

101조

20216736 엄종환

20213222 박수민



목차

- 데이터 소개
- 가설 설정
- 데이터 전처리 과정
- 모델링
- 모델 비교
- 결과 및 기대효과



데이터 소개

데이터 : MIMIC- IV

미국 보스턴 Beth Israel Deaconess Medical Center 응급실 및 중환자실 환자정보를 비 식별화한 대규모 공개 의료 데이터

 diagnosis

 edstays

 patients


 triage

 vital sign

<https://physionet.org/content/mimiciv/3.1/>

데이터 소개

- 설명변수 간 상관관계가 0에 가까움
-> 다중공선성 우려가 적음
- 만약 설명변수 간 상관관계가 1 or -1에 가깝다면
-> 다중공선성 우려가 높음





가설 설정

- 영가설(귀무가설)


: 응급실 도착 후 처음 측정한 활력징후와 주 호소 증상, 나이, 인종, 성별, 주 호소 증상은 입원에 영향을 미치지 않는다.

- 대립가설


: 응급실 도착 후 처음 측정한 활력징후와 주 호소 증상, 나이, 인종, 성별, 주 호소 증상은 입원에 영향을 미친다.

데이터 전처리 과정


- 이상치 값 적용했으나 존재하지 않음
- 총 383906개의 행 중 활력징후의 결측치 값을 **MICE**로 다중대체



데이터 전처리 과정




O2sat
산소포화도




Resprate
호흡 수

데이터 전처리 과정




Dbp
이완기 혈압




Sbp
수축기 혈압

데이터 전처리 과정



Heartrate
심박수



Temperature
체온



데이터 특징

- 입원 환자가 퇴원 환자보다 평균 **14.8세** 더 고령.
- 남성 환자의 입원 비율이 여성보다 상대적으로 높음.
- 입원 그룹에서 백인 환자의 비율이 퇴원 그룹 대비 **15.4%p** 높음.

	HOME (N=237,792)	ADMITTED (N=146,114)	P-value
Age, mean $\pm$ SD	44.8 $\pm$ 18.9	59.6 $\pm$ 18.4	<0.001
Gender, n(%)			<0.001
- F	134,787 (56.7%)	75,393 (51.6%)	
- M	103,005 (43.3%)	70,721 (48.4%)	
Race n(%)			<0.001
- White	125,150 (52.6%)	99,326 (68.0%)	
- Black	60,158 (25.3%)	24,695 (16.9%)	
- Hispanic	23,713 (10.0%)	8,021 (5.5%)	
- Asian	11,859 (5.0%)	5,381 (3.7%)	
- Other	16,912 (7.1%)	8,691 (5.9%)	
Vital sign, mean $\pm$ SD			
- Body temperature, °C	98.0 $\pm$ 0.9	98.2 $\pm$ 1.1	<0.001
- Heartrate, bpm	84.0 $\pm$ 16.5	86.7 $\pm$ 19.2	<0.001
- Respiration rate, bpm	17.3 $\pm$ 1.8	18.0 $\pm$ 2.8	<0.001
- O2 saturation, %	98.8 $\pm$ 1.6	97.8 $\pm$ 2.5	<0.001
- Systolic blood pressure, mmHg	135.6 $\pm$ 20.9	134.2 $\pm$ 24.6	<0.001
- Diastolic Blood Pressure, mmHg	78.8 $\pm$ 13.8	75.1 $\pm$ 16.0	<0.001

P-value for continuous variables were obtained from two-sample t-test. and those for categorical variables from chi-square tests (Fisher's exact test when appropriate).



모델링 - 랜덤포레스트


Call:

```
ranger(formula = outcome ~ ., data = train_data, num.trees = 500, mtry = floor(sqrt(ncol(train_data)
- 1)), importance = "impurity", probability = TRUE)
```

Type:	Probability estimation
Number of trees:	500
Sample size:	307126
Number of independent variables:	19
Mtry:	4
Target node size:	10
Variable importance mode:	impurity
Splitrule:	gini
OOB prediction error (Brier s.):	0.1824455

모델링 - 랜덤포레스트

- **AUC는 0.777**로, triage-ICD 기반 입원 예측 모델이 무작위(0.5)보다 좋은 분류 성능을 가진다.
- **cut-off 0.412**에서 민감도는 **0.676**, 특이도는 **0.738**





모델링 - 랜덤포레스트

- **Accuracy:** 0.714
- **Sensitivity:** 0.677
- **Specificity:** 0.738
- **Precision:** 0.613
- **Recall:** 0.738
- **F1-Score:** 0.762

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	52610	14171
1	18727	29663

Accuracy : 0.7144
95% CI : (0.7117, 0.717)
No Information Rate : 0.6194
P-Value [Acc > NIR] : < 2.2e-16

Kappa : 0.4061

McNemar's Test P-Value : < 2.2e-16

Sensitivity : 0.6767
Specificity : 0.7375
Pos Pred Value : 0.6130
Neg Pred Value : 0.7878
Precision : 0.6130
Recall : 0.6767
F1 : 0.6433
Prevalence : 0.3806
Detection Rate : 0.2576
Detection Prevalence : 0.4202
Balanced Accuracy : 0.7071

'Positive' Class : 1

모델링 - 랜덤포레스트

Variable Importance

- **Shock Index:**


심박수 / 수축기혈압

- **Pulse Pressure:**

수축기 혈압 - 이완기 혈압

- **MAP:**

수축기혈압 + 2 * 이완기혈압 / 3





모델링 - 로지스틱 회귀

```
... Call:
glm(formula = outcome ~ temperature + heartrate + resprate +
    o2sat + sbp + dbp + gender + race + age + icd_category +
    temperature_mi + resprate_mi + sbp_mi, family = binomial,
    data = train_df)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-7.7883094	0.5095331	-15.285	< 2e-16 ***
temperature	0.1648259	0.0044970	36.652	< 2e-16 ***
heartrate	0.0135244	0.0002603	51.948	< 2e-16 ***
resprate	0.0867216	0.0020115	43.114	< 2e-16 ***
o2sat	-0.1093872	0.0022890	-47.787	< 2e-16 ***
sbp	-0.0072541	0.0002255	-32.168	< 2e-16 ***
dbp	-0.0065608	0.0003455	-18.987	< 2e-16 ***
genderM	0.1735746	0.0085691	20.256	< 2e-16 ***
raceBlack	-0.0820690	0.0227170	-3.613	0.000303 ***
raceHispanic	-0.1938615	0.0259865	-7.460	8.65e-14 ***
raceOther	0.1818646	0.0264973	6.864	6.72e-12 ***
raceWhite	0.3333070	0.0214064	15.570	< 2e-16 ***
age	0.0389077	0.0002527	153.996	< 2e-16 ***
icd_categoryCirculatory	-0.9597819	0.0737215	-13.019	< 2e-16 ***
icd_categoryCongenital	-0.4397592	0.1456347	-3.020	0.002531 **
icd_categoryDigestive	-1.0245641	0.0736511	-13.911	< 2e-16 ***
icd_categoryEndocrine/Metabolic	-1.6202593	0.0755704	-21.440	< 2e-16 ***
icd_categoryExternal causes (E)	-0.4454616	0.0942839	-4.725	2.30e-06 ***

icd_categoryGenitourinary	-1.6581731	0.0749461	-22.125	< 2e-16 ***
icd_categoryInfectious	-1.9182636	0.0729547	-26.294	< 2e-16 ***
icd_categoryInjury/Poisoning	-1.8029969	0.0731412	-24.651	< 2e-16 ***
icd_categoryMental	-1.9148146	0.0762788	-25.103	< 2e-16 ***
icd_categoryMusculoskeletal	-2.1980684	0.0750817	-29.276	< 2e-16 ***
icd_categoryNeoplasm	-0.9839409	0.0750268	-13.115	< 2e-16 ***
icd_categoryNervous	-1.7013638	0.0759583	-22.399	< 2e-16 ***
icd_categoryOther	-1.8047299	0.0744665	-24.235	< 2e-16 ***
icd_categoryPerinatal	-1.8673102	0.1098333	-17.001	< 2e-16 ***
icd_categoryPregnancy/Childbirth	-1.0265870	0.0790977	-12.979	< 2e-16 ***
icd_categoryRespiratory	-1.2325223	0.0743593	-16.575	< 2e-16 ***
icd_categorySkin	-1.5138132	0.0777038	-19.482	< 2e-16 ***
icd_categorySymptoms/Signs	-1.7417448	0.0728592	-23.906	< 2e-16 ***
icd_categoryV-codes	-4.1812363	0.1475674	-28.334	< 2e-16 ***
temperature_mi	0.2760711	0.0320337	8.618	< 2e-16 ***
resprate_mi	0.2684391	0.0430949	6.229	4.69e-10 ***
sbp_mi	0.1487921	0.0425331	3.498	0.000468 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 408083 on 307125 degrees of freedom
Residual deviance: 335864 on 307091 degrees of freedom
AIC: 335934


Number of Fisher Scoring iterations: 5

모델링 - 로지스틱 회귀

- **AUC는 0.771**로, triage-ICD 기반 입원 예측 모델이 무작위(0.5)보다 좋은 분류 성능을 가진다.
- **cut-off 0.406**에서 민감도는 **0.654**, 특이도는 **0.751**

... Setting levels: control = 0, case = 1

Setting direction: controls < cases





모델링 - 로지스틱 회귀

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	35743	10105
1	11815	19117

- **accuracy** : 71.5%
- **Sensitivity** : 65.4%
- **Specificity** : 75.2%
- **Pos pred Value** : 61.8%
- **F1- score** : 63.6%

Accuracy : 0.7145

95% CI : (0.7113, 0.7177)

No Information Rate : 0.6194

P-Value [Acc > NIR] : < 2.2e-16

Kappa : 0.4012

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.6542

Specificity : 0.7516

Pos Pred Value : 0.6180

Neg Pred Value : 0.7796

Prevalence : 0.3806

Detection Rate : 0.2490

Detection Prevalence : 0.4029

Balanced Accuracy : 0.7029

'Positive' Class : 1

F1: 0.635601954982212




DCA (Decision Curve Analysis)

모델을 사용하면 환자가 이득을 보는지 보여주는 지표

$$\text{Net Benefit} = \frac{TP}{N} - \frac{FP}{N} \cdot \frac{pt}{1 - pt}$$


모델링 - 로지스틱 회귀

- **X축** : 환자를 고위험으로 간주할 예측 확률 기준이다.
- **Y축** : threshold에서 모델을 썼을 때 얻는 순이익을 0~1 사이로 정규화한 값이다.
- **회색선 (All)**: 묻지도 따지지도 말고 모든 환자를 입원시킨다.
(과잉 진료)
- **검은선 (None)**: 아무도 입원시키지 않고 다 집으로 보낸다.
(방치)
- **빨간선 (Model)**: 로지스틱회귀 모델이 시키는 대로 입원/퇴원을 결정한다.



모델링 - 랜덤포레스트

- **X축** : 환자를 고위험으로 간주할 예측 확률 기준이다.
- **Y축** : threshold에서 모델을 썼을 때 얻는 순이익을 0~1 사이로 정규화한 값이다.
- **회색선 (All)**: 묻지도 따지지도 말고 모든 환자를 입원시킨다.
(과잉 진료)
- **검은선 (None)**: 아무도 입원시키지 않고 다 집으로 보낸다.
(방치)
- **빨간선 (Model)**: 랜덤포레스트 모델이 시키는 대로 입원/퇴원을 결정한다.





모델 비교

로지스틱

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	35743	10105
1	11815	19117

Accuracy : 0.7145

95% CI : (0.7113, 0.7177)

No Information Rate : 0.6194

P-Value [Acc > NIR] : < 2.2e-16

Kappa : 0.4012

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.6542

Specificity : 0.7516

Pos Pred Value : 0.6180

Neg Pred Value : 0.7796

Prevalence : 0.3806

Detection Rate : 0.2490

Detection Prevalence : 0.4029

Balanced Accuracy : 0.7029

'Positive' Class : 1

F1: 0.635601954982212

랜덤포레스트

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	52610	14171
1	18727	29663

Accuracy : 0.7144

95% CI : (0.7117, 0.717)

No Information Rate : 0.6194

P-Value [Acc > NIR] : < 2.2e-16

Kappa : 0.4061

Mcnemar's Test P-Value : < 2.2e-16

Sensitivity : 0.6767

Specificity : 0.7375

Pos Pred Value : 0.6130

Neg Pred Value : 0.7878

Precision : 0.6130

Recall : 0.6767

F1 : 0.6433

Prevalence : 0.3806

Detection Rate : 0.2576

Detection Prevalence : 0.4202

Balanced Accuracy : 0.7071

'Positive' Class : 1

결과 및 기대효과

- 응급실 도착 직후 측정된 환자의 초기 활력징후(vital signs)와 진단 정보(ICD 코드)를 바탕으로, 환자가 입원이 필요한지 여부를 사전에 예측
- 중증도는 낮아 보이지만 입원 가능성이 높은 환자를 조기 식별
- 병상 및 인력 자원 배치를 사전에 최적화
- 응급실 혼잡 상황에서 선제적인 환자 우선순위 결정
- 병원 내 입원 수요 예측 및 운영 효율성 향상

감사합니다